

Fabián Salazar  
Daniel Delgado

Para comenzar con la evaluación, se dividió el conjunto de datos en dos partes utilizando un método de train\_test con un intervalo de 6 meses. Esto permitió entrenar el modelo con una parte de los datos y validar su desempeño en el conjunto de prueba, asegurando la capacidad del modelo para realizar predicciones fiables en un horizonte temporal equivalente.

Inicialmente, se utilizaron las funciones de Autocorrelación (ACF) y Autocorrelación Parcial (PACF) para identificar las características fundamentales de la serie de tiempo. Se implementó un modelo ARIMA para el pronóstico, y se realizaron pruebas exhaustivas utilizando varios criterios de información, incluyendo AIC, AICC, BIC, HQIC y OOB. Tras una comparación detallada, el modelo basado en el criterio AIC se destacó como el mejor, tanto por su menor valor en dicho criterio como por su bajo RMSE. Aunque se consideró la posibilidad de ajustar un modelo ARIMA (1, 1, 1), los resultados confirmaron que el modelo seleccionado por AIC ofrecía un mejor desempeño.

Posteriormente, el modelo ARIMA se ajustó utilizando el conjunto completo de datos para pronosticar los próximos seis meses. Durante la validación de los supuestos del modelo, se encontraron los siguientes resultados:

- **Normalidad de Residuos:** Los residuos del modelo no siguen una distribución normal, lo cual puede impactar en la interpretación de los intervalos de confianza.
- **Homoscedasticidad:** Se comprobó que el modelo cumple con el supuesto de homoscedasticidad, es decir, la varianza de los residuos se mantiene constante a lo largo de la serie.
- **Autocorrelación:** No se encontró evidencia de autocorrelación en los residuos, lo que indica que no quedan patrones no explicados por el modelo.

A pesar de los esfuerzos por ajustar un modelo ARIMA óptimo, la comparación con otros modelos evaluados en semanas anteriores reveló que el modelo de Holt-Winters demostró ser superior.

